

MANUAL TÉCNICO Y METODOLÓGICO DE MODELOS CUANTITATIVOS

Plataforma Institucional de Optimización Multiactivo, Machine Learning, Inferencia Bayesiana y Stress-Testing

FICHA TÉCNICA E INSTITUCIONAL:

- Autoría & Propiedad Intelectual: Rodney Menezes © 2026. Todos los derechos reservados.
- Entidad Académica: Pontificia Universidad Javeriana de Cali - Colombia.
- Pila Tecnológica: Python 3.10, PyTorch (BiLSTM con Atención), Scikit-Learn, SciPy Optimize y Streamlit.

RESUMEN EJECUTIVO & OBJETIVO METODOLÓGICO


El presente manual constituye el compendio técnico de referencia para el Taller de Finanzas Cuantitativas de la Pontificia Universidad Javeriana de Cali - Colombia. Este documento desglosa en profundidad los ocho (8) modelos y paradigmas analíticos que estructuran la plataforma web institucional de inversión: Optimización Media-Varianza regularizada con Ledoit-Wolf, Hierarchical Risk Parity (HRP), Black-Litterman impulsado por Deep Learning, Simulación Monte Carlo multivariada con Cholesky, Backtesting Walk-Forward con ratios asimétricos, Stress-Testing de cuatro crisis financieras globales, Detección no supervisada de Regímenes de Mercado (GMM) y Dinámica analítica de Renta Fija. Cada página ilustra las gráficas nativas generadas por el sistema, analiza sus ecuaciones rectoras, orienta la interpretación práctica de sus resultados y

CONTENIDO Y SECUENCIA METODOLÓGICA:

Pág. 2	Modelo 1: Optimización de Markowitz con Contracción Ledoit-Wolf	(Frontera Eficiente, Utilidad de Arrow-Pratt y autovalores Marchenko-Pastur)
Pág. 3	Modelo 2: Hierarchical Risk Parity (HRP de Marcos López de Prado)	(Clustering jerárquico no supervisado en árbol sin inversión de covarianza)
Pág. 4	Modelo 3: Black-Litterman impulsado por Deep Learning (IA)	(Fusión bayesiana del equilibrio CAPM con vistas probabilísticas de Deep Learning)
Pág. 5	Modelo 4: Simulación Monte Carlo Multivariada (Cholesky)	(Cono de riqueza fan chart, VaR 95% y CVaR 95% (Expected Shortfall))
Pág. 6	Modelo 5: Backtesting Walk-Forward Histórico & Underwater Plot	(Crecimiento patrimonial vs SPY, ratios de Sortino y Calmar, y análisis de drawdown)
Pág. 7	Modelo 6: Stress-Testing Macroeconómico de Crisis Sistémicas	(Simulación de shocks Subprime 2008, COVID 2020, FED 2022 y Ratios de Solvencia)
Pág. 8	Modelo 7: Regímenes de Mercado no Supervisados (Gaussian Mixture Models)	(Región de decisión bayesiana no supervisada en estados Bull, Lateral y Bear)
Pág. 9	Modelo 8: Dinámica Analítica de Renta Fija (Bonos & Sensibilidad)	(Duración Modificada, Convexidad, expansión de Taylor de 2° orden)
Pág. 10	Síntesis Comparativa, Matriz de Decisión Institucional & Marco Legal	Cuadro multidimensional de selección en producción y aviso de producción

MODELO 1: OPTIMIZACIÓN DE MARKOWITZ CON REGULARIZACIÓN LEDOIT-WOLF

Maximización de Utilidad Cuadrática de Arrow-Pratt, Frontera Eficiente y Espectro Marchenko-Pastur



1. ¿POR QUÉ SE USA? (PROBLEMA QUE RESUELVE):

La formulación clásica de Markowitz (1952) optimiza la relación media-varianza. Sin embargo, en la práctica adolece del fenómeno del 'maximizador de errores' de Michaud: la covarianza muestral empírica S sobreestima los autovalores más altos y subestima los más bajos por ruido puro cuando T no es infinitamente mayor que N . El estimador de Ledoit-Wolf (2004) elimina este colapso contrayendo la matriz hacia una estructura bien condicionada F , erradicando ponderaciones hipertrofiadas.

2. ¿CÓMO FUNCIONA? (MECANISMO MATEMÁTICO & ECUACIONES):

Resuelve el problema cuadrático: $\max_w [w^T \mu - (\gamma/2) w^T \Sigma_{LW} w - \text{Costos}]$, donde γ es el coeficiente psicométrico de Arrow-Pratt. La covarianza regularizada se obtiene como: $\Sigma_{LW} = \delta^* F + (1 - \delta^*) S$, donde δ^* minimiza asintóticamente la pérdida cuadrática de Frobenius. La Teoría de Matrices Aleatorias (RMT) demuestra que los autovalores inferiores a $\lambda_+ = \sigma^2 (1 + 1/\sqrt{q})^2$ son ruido blanco que Ledoit-Wolf comprime hacia la correlación media del mercado.

3. ¿CÓMO SE INTERPRETAN SUS RESULTADOS Y GRÁFICOS?:

En el gráfico de la izquierda, la estrella dorada marca la cartera tangente que maximiza la utilidad del inversor para su nivel γ . En el gráfico de la derecha, se observa cómo la covarianza muestral roja presenta autovalores ruidosos inflados, mientras que Ledoit-Wolf (verde) suaviza el espectro, respetando únicamente los modos propios con información genuina de mercado.


4. IMPLICACIONES PRÁCTICAS Y ADVERTENCIAS EN PRODUCCIÓN:

Markowitz ofrece el mayor rendimiento in-sample porque optimiza directamente sobre los retornos pasados. No obstante, si un activo que rindió +100% en el pasado sufre un revés, la cartera puede experimentar drawdowns imprevistos. Por ello, la plataforma exige restricciones de peso máximo ($w_i \leq 25\%$) y costos de transacción explícitos.


MODELO 2: HIERARCHICAL RISK PARITY (HRP) DE MARCOS LÓPEZ DE PRADO

Clustering Jerárquico No Supervisado, Cuasi-Diagonalización y Bisección Recursiva sin Inversión de Matrices

Dendrograma de Dependencia Jerárquica



Asignación de Capital (%) por Paradigma



1. ¿POR QUÉ SE USA? (PROBLEMA QUE RESUELVE):

Todos los estimadores derivados de Markowitz requieren invertir la matriz de covarianza (Σ^{-1}). Cuando existen activos altamente correlacionados o la dimensionalidad N es relevante, la matriz es cuasi-singular y su inversión actúa como un amplificador masivo de ruido estadístico. Marcos López de Prado (2016) introdujo HRP para asignar capital respetando la topología de árbol de los activos, prescindiendo por completo de la inversión de matrices.

2. ¿CÓMO FUNCIONA? (MECANISMO MATEMÁTICO & PASO A PASO):

HRP opera en tres etapas algorítmicas: 1) Clustering Jerárquico: convierte la correlación en métrica euclidiana $d_{ij} = \sqrt{0.5(1 - \rho_{ij})}$ y construye un árbol mediante enlace simple. 2) Cuasi-diagonalización: reorganiza las filas y columnas de la covarianza para agrupar activos con covarianzas similares en bloques adyacentes a la diagonal. 3) Bisección recursiva: divide recursivamente la cartera en subgrupos y asigna ponderaciones inversamente proporcionales a su varianza: $\alpha_1 = 1 - V_1/(V_1 + V_2)$, $\alpha_2 = 1 - \alpha_1$.

3. ¿CÓMO SE INTERPRETAN SUS RESULTADOS Y GRÁFICOS?:


El dendrograma superior muestra cómo el algoritmo aísla a la renta fija (TLT) y al oro (GLD) en ramas separadas de la renta variable. En el gráfico de barras, HRP distribuye el capital de forma mucho más equilibrada que Markowitz, asignando una fracción sustancial a activos amortiguadores y evitando concentraciones excesivas en el líder de momentum reciente.

4. IMPLICACIONES PRÁCTICAS Y COMPORTAMIENTO FUERA DE MUESTRA:

Dado que HRP es completamente agnóstico al vector de retornos esperados μ , no persigue rentabilidades pasadas. En mercados alcistas puede reportar menor retorno in-sample que Markowitz, pero en horizontes out-of-sample reales y cambios de régimen económico, HRP supera sistemáticamente a la media-varianza al exhibir menores drawdowns y máxima robustez estructural.

MODELO 3: BLACK-LITTERMAN IMPULSADO POR DEEP LEARNING (PYTORCH)

Fusión Bayesiana de Equilibrio Implícito CAPM con Vistas Direccionales Probabilísticas de Redes Neuronales BiLSTM



1. ¿POR QUÉ SE USA? (PROBLEMA QUE RESUELVE):

Inventado por Fischer Black y Robert Litterman en Goldman Sachs (1992), resuelve la sensibilidad extrema de Markowitz a las estimaciones de retornos futuros. Si un gestor intenta inyectar pronósticos directos en Markowitz, el optimizador genera carteras erráticas con ventas en corto absurdas y monopolio de activos. Black-Litterman ancla la cartera al equilibrio global del mercado y solo permite desviaciones controladas donde exista convicción estadística real.

2. ¿CÓMO FUNCIONA? (TEOREMA DE BAYES & FUSIÓN CON DEEP LEARNING):

1) Retorno Prior Implícito: $\Pi = \gamma \Sigma w_{mkt}$ (vector de retornos que equilibra la oferta de mercado). 2) Inyección de Vistas de IA: nuestra red neuronal recurrente BiLSTM con auto-atención temporal clasifica la probabilidad softmax direccional de cada activo generando el vector Q. 3) Matriz de Incertidumbre de He-Litterman: $\Omega = \text{diag}(P (\tau \Sigma) P^T) * (1 - \text{Confianza_AI})$. 4) Distribución Posterior: $\mu_{BL} = [(\tau \Sigma)^{-1} + P^T \Omega^{-1} P]^{-1} [(\tau \Sigma)^{-1} \Pi + P^T \Omega^{-1} Q]$.

3. ¿CÓMO SE INTERPRETAN SUS RESULTADOS Y GRÁFICOS?:


En el gráfico de barras, el retorno posterior μ_{BL} (verde) actúa como un promedio ponderado óptimo: cuando la IA posee alta confianza (ej. NVDA con 78%), el retorno posterior se eleva hacia la vista morada Q; cuando la IA tiene baja convicción o es neutral, el posterior se retrae automáticamente hacia el equilibrio macroeconómico gris Π .

4. IMPLICACIONES PRÁCTICAS EN FONDOS CUANTITATIVOS:

Permite utilizar modelos de Machine Learning y Deep Learning de frontera sin asumir riesgos de insolvencia o carteras sobreajustadas. El modelo disciplina a la inteligencia artificial: nunca permite apuestas del 100% en un solo activo y asegura una diversificación institucional matemática con retornos esperados plausibles.

MODELO 4: SIMULACIÓN MONTE CARLO MULTIVARIADA DE TODO EL PORTAFOLIO

Proyección de Riqueza con Descomposición de Cholesky, Cono de Dispersión Fan Chart, VaR 95% y CVaR



1. ¿POR QUÉ SE USA? (PROBLEMA QUE RESUELVE):

Los cálculos estáticos de media y varianza anual no permiten dimensionar los riesgos de ruina en el camino ni las asimetrías del interés compuesto continuo. La simulación Monte Carlo multivariada genera cientos de trayectorias estocásticas conjuntas de todos los activos que componen la cartera, cuantificando la probabilidad real de experimentar caídas patrimoniales severas.

2. ¿CÓMO FUNCIONA? (CHOLESKY & MOVIMIENTO BROWNIANO GEOMÉTRICO):

Para capturar la correlación empírica real, el algoritmo factoriza la matriz regularizada de Ledoit-Wolf: $\Sigma_{LW} = L L^T$. Cada día, proyecta los precios de los N activos mediante: $S_{i,t} = S_{i,t-1} \cdot \exp((\mu_i - 0.5 \sigma_i^2) \Delta t + [L Z]_i \sqrt{\Delta t})$, donde $Z \sim N(0, I)$ es un vector de ruido Gaussiano estándar. El valor total de la cartera evoluciona como: $W_t = \sum (\text{Shares}_i \cdot S_{i,t}) + \text{Cash}$.

3. ¿CÓMO SE INTERPRETAN SUS RESULTADOS Y MÉTRICAS DE RIESGO?:


En el cono de dispersión, la banda verde clara delimita el 90% de los escenarios futuros posibles. En el histograma derecho, el Value at Risk (VaR 95% = $\$ \{mc_res['var_95_dollar']; .2f\}$ USD) indica que en el 95% de los años la pérdida máxima no excederá esa cifra. El CVaR 95% (Conditional VaR o Expected Shortfall = $\$ \{mc_res['cvar_95_dollar']; .2f\}$ USD) cuantifica la pérdida esperada en el peor 5% de los escenarios catastróficos.

4. IMPLICACIONES EN LA GESTIÓN DE TESORERÍA Y APALANCAMIENTO:

Permite al gestor institucional calibrar su colchón de liquidez (Cash Buffer). Si el VaR proyectado compromete las operaciones o excede la tolerancia del comité de riesgos, la plataforma sugiere elevar el parámetro de aversión y o migrar parte del capital hacia activos de renta fija de menor duración.

MODELO 5: BACKTESTING HISTÓRICO WALK-FORWARD & RATIOS ASIMÉTRICOS

Crecimiento Patrimonial Acumulado (\$ USD), Underwater Drawdown Plot, Sortino Ratio y Calmar Ratio



1. ¿POR QUÉ SE USA? (PROBLEMA QUE RESUELVE):

Permite auditar el comportamiento empírico real que habría tenido la estrategia cuantitativa frente a los vaivenes de mercado del pasado reciente. Permite desmitificar promesas teóricas al confrontar la cartera contra el benchmark de mercado (SPY), evaluando tanto la magnitud de las ganancias como el dolor psicológico y patrimonial de las correcciones.

2. ¿CÓMO FUNCIONA? (RATIOS DE SORTINO & CALMAR):

Calcula la evolución de la cartera: $r_{\{p,t\}} = \sum w_i r_{\{i,t\}}$. A diferencia del Sharpe tradicional (que penaliza indistintamente las subidas y las bajadas), el Ratio de Sortino penaliza únicamente la volatilidad bajista: $\text{Sortino} = (R_p - R_f) / \sigma_{\text{downside}}$, donde $\sigma_{\text{downside}} = \sqrt{(1/T) \sum \min(0, r_{\{p,t\}} - R_f)^2}$. El Ratio de Calmar cuantifica la velocidad de recuperación tras drawdowns: $\text{Calmar} = \text{CAGR} / |\text{MaxDrawdown}|$.

3. ¿CÓMO SE INTERPRETAN SUS RESULTADOS Y GRÁFICOS?:


En el gráfico de la izquierda, la curva verde ilustra el alfa o retorno excedente acumulado sobre el benchmark gris. En el gráfico Underwater derecho, las áreas rojas permiten auditar la duración de las fases de recuperación (underwater periods). Un Sortino superior al Sharpe ($\{bt_res['sortino']:.2f\}$ vs $\{bt_res['sharpe']:.2f\}$) certifica asimetría positiva: las ganancias son mayores y más suaves que las correcciones.

4. ADVERTENCIA METODOLÓGICA FUNDAMENTAL (SESGO IN-SAMPLE):

Cuando el backtesting se realiza sobre el mismo período utilizado para estimar μ y Σ , existe un sesgo retrospectivo favorable hacia Markowitz. Por esta razón, el inversor institucional debe contrastar estas métricas contra HRP y Black-Litterman para comprender cómo se comportará la cartera ante cambios estructurales del ciclo económico.

MODELO 6: STRESS-TESTING MACROECONÓMICO DE CRISIS HISTÓRICAS

Simulación de Shocks de Cola Sistémicos: Subprime 2008, COVID 2020, FED Rate Hikes 2022 y AI Rally 2023



1. ¿POR QUÉ SE USA? (PROBLEMA QUE RESUELVE):

En las finanzas reales, las distribuciones de probabilidad tienen colas pesadas (curtosis > 3). Los modelos basados en normalidad y correlaciones estables fallan estrepitosamente en momentos de pánico financiero porque las correlaciones entre acciones convergen a 1. El stress-testing somete la cartera a las crisis macroeconómicas reales más severas de la historia.

2. ¿CÓMO FUNCIONA? (PERFILES DE SHOCK SISTÉMICO CALIBRADOS):

Aplica vectores de contracción calibrados sobre el capital: $W_{crisis} = W_0 * [1 + \sum w_i * s_{\{i,crisis\}}]$. Se simulan 4 escenarios: 1) Subprime 2008 (colapso bursátil -48%, subida de bonos +20% y oro +15%). 2) COVID-19 2020 (shock pandémico -34%, colapso petrolero -60%). 3) FED Rate Hikes 2022 (shock inflacionario con caída simultánea de acciones y bonos TLT -31%). 4) AI Rally 2023 (+120% tech).

3. ¿CÓMO SE INTERPRETAN SUS RESULTADOS Y GRÁFICOS?:


En el gráfico izquierdo, se aprecia cómo la cartera diversificada con renta fija y materias primas resiste mejor las caídas que el clásico portafolio 60/40. En el desglose derecho, se observa el efecto de compensación: las pérdidas de las acciones cíclicas quedan neutralizadas por la revalorización de los bonos del tesoro (TLT) y el oro (GLD).

4. IMPLICACIONES EN EL DISEÑO DE COBERTURAS (HEDGING):

El escenario 2022 demostró que los bonos no siempre protegen si el detonante de la crisis es una inflación desanclada. Esto justifica la inclusión obligatoria de activos reales descorrelacionados como el oro (GLD), energía (XLE) y bienes raíces (VNQ) para garantizar resiliencia en cualquier régimen macroeconómico.

MODELO 7: DETECCIÓN NO SUPERVISADA DE RÉGIMENES DE MERCADO (GMM)

Modelos de Mixturas Gaussianas en Espacio Retorno-Volatilidad y Clasificación Bayesiana de Estados en Tiempo Real



1. ¿POR QUÉ SE USA? (PROBLEMA QUE RESUELVE):

Los mercados financieros no son estacionarios; alternan entre períodos de baja volatilidad con crecimiento sostenido y fases de pánico súbito con alta dispersión. Los modelos que asumen una única distribución estática fallan. Gaussian Mixture Models (GMM) permite identificar de forma no supervisada en qué estado macroeconómico se encuentra el mercado en tiempo real.

2. ¿CÓMO FUNCIONA? (INFERENCIA BAYESIANA NO SUPERVISADA CON EM):

Ajusta una combinación convexa de $K=3$ densidades Gaussianas multivariadas: $p(x) = \sum \pi_k N(x | \mu_k, \Sigma_k)$, donde $x_t = [\text{Retorno}_{1d}, \text{Volatilidad}_{10d}]$. Utiliza el algoritmo de Esperanza-Maximización (EM) para estimar las medias μ_k y matrices de covarianza Σ_k de cada estado latente, asignando a cada fecha una probabilidad posterior bayesiana de pertenecer a cada régimen.

3. ¿CÓMO SE INTERPRETAN SUS RESULTADOS Y GRÁFICOS?:


En el gráfico izquierdo, se observan tres nubes bien diferenciadas: el régimen verde ([Bull]): retornos positivos con volatilidad baja/moderada), el régimen amarillo ([Lateral]): retornos comprimidos cerca de cero) y el régimen rojo ([Bear]: dispersión extrema con retornos marcadamente negativos). En la serie temporal derecha, se aprecia cómo el modelo aísla correcciones de mercado.

4. APLICACIÓN TÁCTICA EN REBALANCEO DINÁMICO DE CARTERAS:

El régimen diagnosticado en tiempo real condiciona la política de inversión: en Régimen Bull, se recomienda mantener la asignación óptima de renta variable; en Régimen Bear, se activa una regla de reducción de riesgo, elevando el colchón de efectivo (Cash Buffer) o sobreponderando instrumentos de renta fija de alta calidad crediticia.

MODELO 8: DINÁMICA ANALÍTICA DE RENTA FIJA (DURACIÓN & CONVEXIDAD)

Sensibilidad del Precio ante Shocks de Rendimiento (Δy), Expansión de Taylor de Segundo Orden y DV01



1. ¿POR QUÉ SE USA? (PROBLEMA QUE RESUELVE):

La renta fija no es un activo estático; su precio oscila inversamente a las tasas de interés fijadas por la Reserva Federal (FED). Modelar analíticamente su duración y convexidad es vital para predecir con exactitud cómo variará el valor de la cartera ante movimientos de la curva soberana y diseñar coberturas macroeconómicas efectivas.

2. ¿CÓMO FUNCIONA? (EXPANSIÓN DE TAYLOR & MÉTRICAS ANALÍTICAS):

El precio exacto descuenta los flujos futuros: $P(y) = \sum C_t / (1+y)^t$. Aproximando por serie de Taylor de segundo orden: $\Delta P/P \approx -D^* \Delta y + 0.5 C (\Delta y)^2$. Donde $D^* = -(1/P) dP/dy$ es la Duración Modificada Efectiva (en años), $C = (1/P) d^2P/dy^2$ es la Convexidad, y el DV01 ($\$ \text{cambio monetario por cada punto básico de variación en el rendimiento}$) mide el cambio monetario por cada punto básico de variación en el rendimiento.

3. ¿CÓMO SE INTERPRETAN SUS RESULTADOS Y GRÁFICOS?:

En el gráfico de re-pricing, la recta roja lineal subestima el precio cuando las tasas bajan y sobreestima las caídas cuando las tasas suben. La curvatura verde y azul demuestra la convexidad: es una propiedad asimétrica favorable que actúa como un amortiguador natural contra pérdidas y un acelerador de ganancias. El gráfico derecho muestra cómo Taylor 2° orden mantiene un error casi nulo.

4. ROL EN LA OPTIMIZACIÓN MULTIACTIVO DE LA CARTERA:

El ETF de renta fija cotizado en Yahoo Finance entra directamente en la matriz de covarianza de Markowitz y Ledoit-Wolf. Al poseer correlaciones bajas o negativas con la renta variable, reduce sustancialmente la varianza del portafolio global y permite alcanzar ratios de Sharpe significativamente más altos.

SÍNTESIS COMPARATIVA, GUÍA DE DECISIÓN Y MARCO LEGAL INSTITUCIONAL

Evaluación Multidimensional de Modelos, Matriz de Selección Práctica y Aviso de Propiedad Intelectual

CUADRO COMPARATIVO MULTIDIMENSIONAL DE PARADIGMAS CUANTITATIVOS:

Criterio	Markowitz (Ledoit-Wolf)	Hierarchical Risk Parity (HRP)	Black-Litterman (IA BiLSTM)
Filosofía	Maximización de Utilidad (Media-Varianza)	Paridad de Riesgo en Árbol Jerárquico	Inferencia Bayesiana de Equilibrio + IA
Uso de Retornos (μ)	Sí (vector histórico de retornos)	NO (completamente agnóstico a retornos)	Sí (vistas direccionales con incertidumbre)
Inversión de Covarianza	Sí (requiere regularización Σ_{LW}^{-1})	NO (erradica inversión mediante bisección)	Sí (sobre la covarianza del prior $\tau\Sigma$)
Rendimiento In-Sample	Máximo (optimiza sobre la serie pasada)	Moderado (conservador en rallies alcistas)	Equilibrado (disciplinado por el mercado)
Robustez Out-of-Sample	Sensible a cambios de régimen futuro	Máxima (la más robusta ante turbulencias)	Baja (no permite apuestas destructivas)
Complejidad Algorítmica	Optimización cuadrática SLSQP	Machine Learning no supervisado en árboles	Deep Learning PyTorch + Álgebra matricial

MATRIZ DE DECISIÓN INSTITUCIONAL: ¿CUÁL MODELO SELECCIONAR EN PRODUCCIÓN?

- Seleccione MARKOWITZ (con Ledoit-Wolf):**
Cuando el inversor posee un perfil psicométrico de riesgo bien definido (y conocido) y se busca maximizar la eficiencia del capital en horizontes estables donde se espera continuidad en las tendencias de retorno relativo de los activos.
- Seleccione HIERARCHICAL RISK PARITY (HRP):**
En fases de alta incertidumbre macroeconómica, volatilidad sistémica o cuando no se confía en pronósticos de retornos futuros. HRP garantiza la mayor diversificación genuina y es el modelo de mejor desempeño en preservación de capital out-of-sample.
- Seleccione BLACK-LITTERMAN (impulsado por IA):**
Cuando se desea capturar las señales de modelos de Inteligencia Artificial (Deep Learning BiLSTM con auto-atención temporal) pero con el rigor de un comité institucional de riesgos, evitando el sobreajuste y estabilizando la cartera contra el equilibrio global.
- Directriz de Gobernanza de Riesgos:**
La mejor práctica cuantitativa no consiste en casarse con un único modelo, sino en ejecutar los tres en paralelo como lo hace esta plataforma: Markowitz como benchmark de utilidad, HRP como ancla de resiliencia y Black-Litterman como motor táctico.

DECLARACIÓN DE AUTORÍA Y PROPIEDAD INTELECTUAL

Todos los derechos reservados © 2026 Rodney Menezes. El diseño metodológico, algoritmos cuantitativos, modelos econométricos, arquitecturas de Deep Learning (Redes Neuronales BiLSTM con Auto-Atención Temporal en PyTorch) e implementaciones de código de esta plataforma han sido concebidos y desarrollados por Rodney Menezes con fines académicos, didácticos y de investigación avanzada para el Taller de Finanzas Cuantitativas en la Pontificia Universidad Javeriana de Cali - Colombia. Queda estrictamente prohibida su reproducción total o parcial, distribución, modificación o explotación comercial no autorizada sin el consentimiento expreso por escrito del autor titular.